

Reconhecimento de Dígitos Manuscritos com Redes Neurais Convolucionais

Filipe Tchivela
3º Ano, Ciência da Computação
Universidade Mandume

Maio de 2025

Abstract

Este projeto apresenta o desenvolvimento de um sistema de reconhecimento de dígitos manuscritos utilizando o dataset MNIST e redes neurais convolucionais (CNNs). O objetivo foi alcançar uma acurácia superior a 99% em um conjunto de teste, com uma interface interativa para demonstração. O projeto envolveu pré-processamento de dados, treinamento de modelos, validação cruzada, e deploy de uma aplicação Streamlit. Este relatório detalha o processo, as mudanças realizadas e os resultados obtidos.

1 Introdução

O reconhecimento de dígitos manuscritos é um problema clássico de aprendizado de máquina, com aplicações em automação de tarefas como leitura de cheques e formulários. O dataset MNIST, composto por 60.000 imagens de treino e 10.000 imagens de teste (28x28 pixels, em escala de cinza), foi usado para treinar uma rede neural convolucional (CNN) capaz de classificar dígitos de 0 a 9 com alta precisão.

2 Metodologia

2.1 Carregamento e Pré-processamento

Inicialmente, o conjunto de teste (`mnist_test.csv`) foi carregado e explorado no Google Colab, com visualização de imagens e normalização dos pixels (de 0-255 para 0-1). Devido ao tamanho do `mnist_train.csv`, optou-se por usar o dataset MNIST do `tensorflow.keras.datasets` que oferece os mesmos dados de forma eficiente. As imagens foram remodeladas para o formato (28, 28, 1) para uso em CNNs.

2.2 Evolução do Modelo

- **Passo 1:** Uma rede neural densa simples foi testada, mas a acurácia ficou abaixo de 99% devido à limitação do modelo em capturar padrões espaciais.

- **Passo 2:** Uma CNN inicial com duas camadas convolucionais e dropout foi implementada, alcançando acurácia próxima de 98-99%.
- **Passo 3:** A CNN foi aprimorada com mais camadas convolucionais, batch normalization, e dropout (0.25 e 0.5), além de validação cruzada (k=5) para garantir robustez. A acurácia média na validação cruzada foi superior a 99%, e a avaliação no `mnist_test.csv` confirmou desempenho similar.

2.3 Motivação das Mudanças

- **Substituição do `mnist_train.csv`:** O dataset do Keras foi usado para evitar problemas com o tamanho do arquivo, mantendo a compatibilidade com o `mnist_test.csv`.
- **CNN vs. Rede Densa:** CNNs são mais eficazes para imagens devido à capacidade de capturar padrões espaciais via filtros convolucionais.
- **Batch Normalization e Dropout:** Adicionados para melhorar a generalização e evitar overfitting, garantindo acurácia $\geq 99\%$.
- **Validação Cruzada:** Assegurou que o modelo é robusto em diferentes subconjuntos de dados.

3 Aplicação Streamlit

Uma interface interativa foi desenvolvida com Streamlit, permitindo:

- Desenhar dígitos em um canvas.
- Fazer upload de imagens.
- Exibir previsões com probabilidades.

A aplicação foi implantada no Streamlit Community Cloud, com design premium e seção "Sobre Mim" destacando o autor (Filipe Tchivela, 3º Ano, Ciência da Computação, Universidade Mandume).

4 Resultados

- **Acurácia:** $\geq 99\%$ no `mnist_test.csv`.
- **Relatório de Classificação:** Alta precisão, recall e F1-score para todas as classes.
- **Matriz de Confusão:** Poucos erros, concentrados em dígitos visualmente semelhantes (ex.: 4 e 9).
- **Aplicação:** Interface funcional com testes em tempo real.

5 Conclusão

O projeto atingiu o objetivo de acurácia $\geq 99\%$ com uma CNN robusta, validada por técnicas modernas de aprendizado de máquina. A aplicação Streamlit oferece uma demon-

stração prática e acessível, ideal para apresentações acadêmicas. Futuras melhorias podem incluir suporte a imagens coloridas ou maior robustez a ruídos.

6 Agradecimentos

Agradeço à Universidade Mandume e aos colegas pelo apoio durante o desenvolvimento deste projeto.